

CODEFEST AD ASTRA 2026

Documento tecnico — Etapa 1: Base de Conocimiento Vectorial

1. El corpus y su preprocesamiento

El corpus entregado por ADL son **1826 documentos** (3 GB) de 21 observatorios repartidos en los tres fenomenos: 760 PDF, 964 JSON, 26 CSV, 73 PBF, 8 imagenes, 6 XLSX y 1 TXT. La heterogeneidad es el primer problema de ingenieria del reto: un mismo indice tiene que absorber informes de 400 paginas de SIPRI o del AI Index, articulos web serializados en JSON, datasets bibliograficos de decenas de MB y teselas de mapas vectoriales. De los 1826 documentos, **1818 aportan texto**; los 8 restantes son 5 imagenes sin texto legible, un JSON vacio y dos archivos con extension *.pdf* que en realidad son paginas HTML de error de la descarga.

Cada formato de origen tiene un extractor dedicado que produce un objeto comun (*RawDocument*) con el texto crudo y metadata auxiliar: **PDF** (pypdfium2, preservando el orden de lectura por pagina y con deteccion heuristica de boilerplate — lineas identicas repetidas en $\geq 30\%$ de las paginas de un documento de 3 o mas paginas se descartan como cabecera/pie de pagina), **HTML** (trafilatura, que separa el contenido principal del menu de navegacion, anuncios y pie de pagina, y preserva encabezados como senales Markdown), **JSON** (mapeo explicito de campos conocidos como *title/body_paragraphs/body_text*, con fallback generico para esquemas no anticipados), **CSV/XLSX** (cada fila se convierte en pares *columna: valor* y se trata como unidad atomica de fragmentacion) e **imagenes** (OCR opcional via pytesseract, con degradacion controlada si el binario de tesseract no esta disponible). Tres decisiones merecen justificacion explicita porque las impuso el corpus real:

- **pypdfium2 en vez de pdfplumber** para los PDF. Con 760 PDF y del orden de 30.000 paginas, el costo de extraccion deja de ser irrelevante: medido sobre este corpus, pypdfium2 lee unas 3.000 paginas en 4,5 s, mientras que pdfplumber es dos ordenes de magnitud mas lento y convierte la fase offline de minutos en horas. Para texto plano de informes la calidad extraida es equivalente.
- **OCR selectivo.** Cerca del 5% de los PDF — casi todos los informes de riesgo de la Defensoria del Pueblo — son escaneos sin capa de texto. Cuando un documento rinde menos de 200 caracteres por pagina se asume escaneo y se rasteriza para pasarlo por tesseract, con un tope de 60 paginas por documento: sin ese tope un puñado de escaneos largos domina el tiempo total de la corrida.
- **Los .pbf no son OpenStreetMap.** Las 73 teselas de Amazon Underworld son *Mapbox Vector Tiles*, no el formato Protocol Buffer de OSM, asi que las librerias habituales (pyosmium, pyrosm) no las leen. Se decodifican con *mapbox-vector-tile*, se recorren las capas leyendo los atributos de cada elemento como pares *atributo: valor*, y se deduplican los elementos repetidos entre niveles de zoom, tal como indica la sec. 2.1.

Los CSV/XLSX llevan un tope de 500 filas por archivo. Los datasets del AI Index son volcados bibliograficos de PubMed de hasta 35 MB, ajenos a las consultas del reto: sin tope aportarian mas de 100.000 fragmentos de ruido que dominarian el espacio vectorial. Con tope, el documento sigue indexado y puede recuperarse a nivel documento, pero no ahoga al resto del corpus. La limpieza posterior (normalizacion Unicode NFC, remocion de caracteres de control, deteccion de idioma) es deliberadamente conservadora sobre el contenido — sin lowercasing ni stemming — porque la evaluacion compara el campo *text* de forma textual contra el ground truth.

1.1 Identificacion de documentos (doc_id)

El emparejamiento a nivel documento se hace con el **DOC_ID** que **suministra ADL** en el inventario del corpus (formato *F1-AIINDEX-001*), no con un identificador propio. El manifest se indexa por **ruta relativa** y no por nombre de archivo: 59 nombres del inventario aparecen en dos carpetas distintas con **DOC_ID** distintos — los informes de CSET bajo *pdfs/Reports* y *pdfs/Translation*, y las teselas que se repiten por nivel de zoom — de modo que indexar por nombre le habria asignado el identificador equivocado a 127 documentos y anulado su aporte al F1@3. Once archivos presentes en el corpus no figuran en el inventario de ADL (catalogos y registros del proceso de descarga); al no tener **DOC_ID** no pueden aparecer en el ground truth, y se excluyen del indice para que no ocupen uno de los tres cupos de documento por consulta.

2. Estrategia de chunking y justificacion

Se implemento una estrategia **hibrida estructural + oracional con solapamiento**, en tres niveles:

- **Estructural:** el texto se separa primero por encabezados Markdown (que HTML/JSON/MD ya traen marcados por el extractor); si el documento no tiene encabezados (caso tipico de PDF), se trata como una unica seccion.
- **Segmentacion de oraciones multilingue:** dentro de cada seccion, se usa *pysbd* (reglas linguisticas dedicadas) para espanol e ingles, y el parser entrenado de spaCy (*pt_core_news_sm*) para portugues, que *pysbd* no cubre nativamente.
- **Empaquetado voraz por presupuesto de tokens** (~280 tokens, margen bajo el limite de 512 del encoder), contando tokens con el tokenizer real del encoder de indexacion — no una aproximacion por palabras — con **solapamiento de 1 oracion** entre chunks consecutivos para no perder ideas que caen en la frontera.

La unidad minima que se mueve entre chunks es siempre una oracion completa: el empaquetador nunca corta un caracter a mitad de oracion, cumpliendo el requisito de completitud linguistica (sec. 3.3). Esta garantia se verifica automaticamente en *tests/test_chunking.py*. La unica excepcion estructural es CSV/XLSX, donde cada fila (no una oracion en lenguaje natural) se indexa como chunk atomico, tal como permite explicitamente la especificacion.

3. Encoder(s) seleccionado(s) y criterios de eleccion

Encoder primario: **sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2** (arquitectura encoder tipo BERT, licencia Apache 2.0).

Criterio	Justificacion
Soporte multilingue	Cubre nativamente espanol, ingles y portugues (50+ idiomas), necesario porque el corpus y las consultas mezclan los tres.
Dimensionalidad	384 dimensiones: balance razonable entre costo de almacenamiento/busqueda y expresividad para el volumen esperado del reto.
Longitud maxima de entrada	512 tokens; el presupuesto de chunking (~280 tokens) deja margen suficiente.
Licencia	Apache 2.0, uso libre sin restricciones para el contexto del reto.
Eficiencia computacional	Modelo liviano (backbone MiniLM), adecuado para los recursos de computo limitados del equipo.

Riesgo de reproducibilidad	Ya validado en el material de apoyo entregado por el equipo organizador (01_embeddings.ipynb, 02_rag.ipynb), reduciendo el riesgo de incompatibilidades de ultimo momento.
----------------------------	--

3.1 Encoder secundario y fusion de rankings (sec. 4.4)

El pipeline soporta construir la base con mas de un encoder. El secundario es **intfloat/multilingual-e5-base** (encoder tipo BERT, licencia MIT, 768 dimensiones, multilingue nativo, limite 512 tokens). El criterio de seleccion no fue elegir un modelo "mejor" en abstracto, sino uno con **errores decorrelacionados** respecto al primario: E5 esta entrenado para recuperacion densa mientras que el primario esta afinado para similitud de parafrasis. Fusionar dos rankings solo aporta cuando los modelos se equivocan en casos distintos; dos encoders de la misma familia habrian aportado poco.

La familia E5 exige prefijos distintos para consulta (*query:*) y pasaje (*passage:*); omitirlos degrada la calidad silenciosamente. Por eso la interfaz *Encoder* distingue codificacion asimetrica (*encode_query / encode_passages*), y los encoders que no los requieren heredan el comportamiento por defecto.

Las listas se combinan con **Reciprocal Rank Fusion** (RRF, ecuacion 7, con $k_0=60$), elegido sobre CombSUM/CombMNZ porque opera sobre posiciones y no sobre puntuaciones absolutas: es robusto a que dos encoders produzcan similitudes en escalas distintas. El grafo de conocimiento se incorpora como una lista adicional a fusionar, tal como sugiere la sec. 8.5.

Invariante de correccion: la fusion empareja fragmentos por *chunk_id*, lo que solo es valido si todos los indices comparten los mismos fragmentos. Como el presupuesto de chunking depende del tokenizer, fragmentar por separado con cada encoder produciria *chunk_id* colisionantes apuntando a textos distintos. Por eso el chunking se ejecuta una unica vez y sus fragmentos se reutilizan para todos los encoders; *generador.py* ademas verifica la coincidencia al cargar y aborta si detecta indices desincronizados, en lugar de producir resultados silenciosamente incorrectos.

Resultado de la medicion: se entrega con un solo encoder. Se construyo el indice completo con *multilingual-e5-base* (128.526 fragmentos, unas cinco horas de CPU) y se comparo contra el primario y contra la fusion RRF de ambos, sobre el ground truth propio descrito en la seccion 7. El primario resulto mejor en todas las mediciones:

Configuracion	F1@3 (10 indep.)	F1@3 (41 consultas)	Consultas ganadas vs. primario
MiniLM (entregada)	0,300	0,306	—
multilingual-e5-base solo	0,133	0,182	pierde 2-5 y 7-17
Fusion RRF de ambos	0,167	0,268	pierde 1-5 y 8-13

Antes de concluir se verifiko que el segundo encoder no estuviera mal empleado, porque la familia E5 degrada en silencio si se omiten sus prefijos: se confirio que la indexacion aplica *passage:* y la consulta *query:*, tanto en el pipeline como en la copia autocontenida de *generador.py*. El bajo rendimiento es real, no un error de uso.

La decision es solida porque los dos criterios apuntan al mismo lado: la configuracion de un solo encoder es a la vez **la mas simple y la mejor medida**, y no hay que elegir entre ambas cosas. Entregar dos indices habria duplicado el tamano de la entrega y el costo de indexacion para empeorar el resultado. La capacidad multi-encoder queda implementada y probada detras de `--encoder-name A B`, disponible si el corpus cambiara, pero desactivada por defecto.

No se emplea ningún modelo decoder/generativo en ninguna etapa de indexación o recuperación (sec. 4.2 y 8.3): en particular, se descarto explícitamente HyDE (requiere un LLM para generar una respuesta hipotética) y el reranking con LLM. El uso de un *cross-encoder* (arquitectura encoder, no generativa, demostrado en el material de apoyo) quedó implementado detrás de un flag desactivado por defecto, como exploración documentada, para no depender de él en el flujo evaluado.

4. Índice FAISS

Se utiliza **IndexFlatIP** sobre vectores normalizados a norma unitaria, equivalente a similitud coseno (sec. 5.2 y 8.2). Es la opción recomendada por la propia especificación para el volumen de documentos esperado en esta etapa del reto: garantiza resultados exactos (sin la pérdida de exactitud de IVFFlat/HNSW) y su costo computacional es totalmente asumible a esta escala. El identificador interno de FAISS se mantiene alineado línea a línea con *metadata.jsonl* (mismo orden de inserción que de escritura), invariante verificado en *tests/test_faiss_alignment.py*. Si el corpus real de ADL resultara mucho mayor al esperado, *src/config.py* centraliza el punto donde migrar a un índice aproximado sin tocar el resto del pipeline.

La decisión se verificó empíricamente antes de fijarla. Con vectores de 384 dimensiones y $k=120$ sobre CPU, una búsqueda exacta tarda 1,9 ms (mediana) con 20.000 vectores, 5,7 ms con 50.000 (9,8 ms en el percentil 99) y 13,2 ms con 100.000. El corpus real produce **128.526 fragmentos**, es decir del orden de 15 ms por consulta: irrelevante frente a los ~27 ms que cuesta vectorizar la consulta y los ~19 s de carga del encoder. Migrar a IVFFlat o HNSW habría cambiado búsqueda exacta por búsqueda aproximada — perdiendo recall, que es justamente lo que mide la evaluación — a cambio de ahorrar milisegundos que nadie percibe.

5. Grafo de conocimiento (componente bonus)

NER: se usa el componente de reconocimiento de entidades ya entrenado en los modelos spaCy *es/en/pt_core_news_sm* (licencia MIT, arquitectura no generativa), filtrando tipos de entidad puramente numéricos/temporales (fechas, cantidades, porcentajes) para quedarse con personas, organizaciones, lugares y otras entidades nombradas relevantes.

Extracción de relaciones: heurística basada en dependencias sintácticas (permitida explícitamente por la especificación como alternativa a un modelo entrenado de RE): para cada oración con al menos dos entidades, se toma el verbo/auxiliar entre un par de entidades consecutivas como etiqueta de relación (o el verbo raíz de la oración si no hay uno intermedio), con una relación genérica de co-ocurrencia como último recurso.

Construcción e integración: las tripletas se acumulan en un *networkx.MultiDiGraph*, cada arista con *doc_id*, *chunk_id* y la relación como evidencia trazable, exportado a GraphML. En recuperación, las mismas entidades se detectan en la consulta, se buscan sus vecinos de primer orden en el grafo, y los chunks vinculados se fusionan con el ranking vectorial mediante Reciprocal Rank Fusion (el grafo se trata como un índice adicional, sec. 8.5), detrás de un flag *--use-graph* opcional en *generador.py*.

El grafo sobre el corpus real tiene 224.101 nodos y 754.876 aristas, construidas a partir de 1.687 documentos. Dos decisiones lo hicieron utilizable. La primera: se excluyen los formatos sin narrativa (CSV, XLSX y las teselas vectoriales, el 17,7% de los fragmentos), porque el NER busca entidades nombradas en lenguaje natural y aplicado a una fila de tabla produce ruido — las entidades más frecuentes de una versión preliminar eran *FALSO*, *VERDADEIRO* y el nombre de una capa de mapa. La segunda: los

nombres de entidad se limpian de caracteres de control, que el texto de OCR arrastra y que hacen fallar la exportacion a GraphML, un formato XML que no los admite.

El grafo se entrega, pero los resultados se generan sin el. Medida su fusion con el ranking vectorial contra el ground truth propio, no mejora en ninguna consulta de las 10 de anotacion independiente (pierde 3-0) y gana solo 1 de 41 en el conjunto completo (pierde 7-1). Se entrega por tanto el artefacto, que es lo que pide la seccion 7, con la recuperacion en su configuracion puramente vectorial. Que el componente bonus exista y sea trazable al corpus no obliga a degradar la metrica usandolo.

6. Modulo de recuperacion

- Mismo encoder para indexacion y consulta; vector de consulta normalizado igual que el indice.
- Sobre-recuperacion de candidatos antes de aplicar post-filtros de metadata (fenomeno, formato, idioma) o de umbral de similitud coseno (sec. 8.7).
- Agregacion a nivel documento por **suma** de las puntuaciones de sus fragmentos (configurable a maximo o media) sobre un pool de 60 candidatos, mas amplio que los 10 fragmentos mostrados, para que la relevancia de un documento no dependa solo de si su mejor chunk aparece en el top-10 (sec. 8.6). La eleccion de la suma sobre el maximo esta medida, no supuesta: ver seccion 7.
- Reciprocal Rank Fusion ($k_0=60$) como mecanismo unico de combinacion, reusado tanto para multiples encoders como para vector+grafo (sec. 8.4).
- Limite de 250 palabras por fragmento aplicado dividiendo en limites oracionales completos cuando un chunk lo excede; los sub-fragmentos comparten *chunk_id* y ocupan su propio *rank* (sec. 9.2.1). El corpus real obligo a agregar un ultimo recurso: en texto proveniente de OCR la puntuacion puede desaparecer por completo y el segmentador devuelve una unica "oracion" de mas de 250 palabras, que respetar el limite oracional dejaria pasar entera. En ese caso — y solo en ese — el corte se hace por palabras.
- **Supresion de fragmentos con texto repetido.** El corpus contiene documentos duplicados (el mismo informe de CSIS bajo dos *doc_id*, series que reeditan capitulos completos), de modo que dos fragmentos distintos del indice pueden tener texto identico. Entregar el mismo texto dos veces no puede aportar ganancia en NDCG@10 — el ranking ideal no lo contiene — y ademas desplaza fuera del top-10 a un candidato que si podria aportarla. Sobre las 50 consultas oficiales, 17 de los 500 fragmentos entregados eran duplicados exactos; suprimirlos y completar el cupo con el siguiente candidato recupera esos 17 espacios. La comparacion es de texto exacto (normalizando solo espacios y mayusculas) y no de similitud aproximada, que podria descartar fragmentos legitimamente distintos que comparten un parrafo.

Ninguna etapa de recuperacion usa un modelo generativo: solo vectores, puntuaciones de similitud coseno y aritmetica sobre metadata.

7. Como se tomaron las decisiones: medicion interna

El ground truth oficial no es publico durante el reto, de modo que ninguna decision de diseno puede validarse contra la metrica real. Para no elegir a ojo se construyo uno propio (*dev/eval*) que cubre **las 50 consultas oficiales**: 41 con documentos relevantes marcados y 9 en las que se reviso candidato por candidato sin que ninguno respondiera. Se construyo en dos etapas y la distincion es importante para no enganarse:

- **10 consultas de anotacion independiente.** Los candidatos salieron de contar palabras clave sobre el texto extraido, *sin pasar por el recuperador*. Son las unicas validas para comparar dos encoders entre si.
- **31 consultas por *pooling*** (la tecnica de TREC): los candidatos los propuso el propio sistema y se marcaron leyendo sus extractos. Aportan volumen, pero una consulta cuyos candidatos propuso el encoder X favorece a X, porque un documento que X nunca recupero no pudo marcarse como relevante. Por eso cada linea del ground truth registra su procedencia y las herramientas de evaluacion tienen una opcion *--sin-pooling*.

El sesgo resulto menor de lo temido: el F1@3 da 0,306 sobre las 41 consultas y 0,300 sobre las 10 independientes. La razon es que los candidatos se proponen con un pool de 200 mientras la configuracion entregada usa 60, de modo que las marcas no se cumplen solas. Sobre esta base, *scripts/barrido_retrieval.py* carga el indice una vez y evalua en memoria todas las combinaciones de tamano de pool y estrategia de agregacion.

La configuracion entregada agrega por **suma** de las puntuaciones de los fragmentos de cada documento, en lugar de por **maximo**. En promedio la suma rinde mejor (F1@3 de 0,306 frente a 0,226 sobre las 41 consultas anotadas), pero conviene ser preciso sobre la fuerza de esa evidencia: contando por consulta, la suma gana en 16 y el maximo en 8, con 17 empates. Una prueba de signos sobre las 24 que difieren da **p = 0,15**; sobre las 10 consultas de anotacion independiente el reparto es 4-2 (p = 0,69). **La ventaja no alcanza significancia estadistica con esta muestra.**

Se entrega igualmente la suma, y la razon principal no es el promedio sino el argumento estructural: un documento verdaderamente relevante para una consulta contiene *varios* pasajes relevantes, mientras que el maximo premia al documento que tuvo un unico fragmento afortunado. La suma ademas gana en ambas muestras y no pierde en ninguna, y no es mas compleja de implementar. Se documenta asi, y no como un resultado medido, porque la diferencia entre "lo medimos" y "lo argumentamos y el dato no lo contradice" es justamente lo que evita sobreajustar a un ground truth reducido.

El promedio de F1@3 no basta para decidir, y conviene explicar por que. El tamano del pool parecia importar: con 26 consultas, un pool de 30 daba 0,309 frente a 0,274 con 60, y la ventaja se repetia al medirla con 10, 19 y 26 consultas. Contando por consulta en vez de promediar, el resultado es otro: **30 gana en 5 consultas, 60 gana en 3 y empatan 18**. Un reparto 5-3 sobre las ocho que difieren es lo que produce el azar. Con del orden de 30 consultas cada una pesa 0,033 en la media, asi que dos que cambien de lado mueven el promedio mas que cualquier efecto real. El pool se dejo en 60 y *barrido_retrieval.py* incorporo la comparacion por conteo de victorias, que es la herramienta correcta para la decision entre encoders.

El mismo criterio descarto otras tres hipotesis que parecian prometedoras: que fallara la recuperacion entre idiomas distintos (2 de 5 aciertos con documentos en ingles frente a 3 de 5 en espanol, sin diferencia con esa muestra); que el sistema ignorara los terminos discriminantes de la consulta (de las siglas de las 50 consultas la unica ausente del corpus es NBQR, y afecta a una sola consulta); y que confundiera los grupos armados ilegales con las fuerzas armadas estatales (medido con un patron justo, afecta al 8% de los cupos de documento, no a la mayoria). Se documentan porque el riesgo real de un ground truth reducido no es medir de menos sino *sobreajustar*: presentar cada pico de un barrido como hallazgo degradaria las consultas no observadas.

La entrega se verifica de punta a punta antes de empaquetarse con *scripts/validar_entrega.py*, que comprueba la estructura de carpetas, las 50 lineas, los 3 documentos y 10 fragmentos por consulta, el limite de 250 palabras, la alineacion entre el indice FAISS y *metadata.jsonl*, y que todo *doc_id* reportado

pertenezca al inventario de ADL. La suite de pruebas (51 casos) cubre los invariantes criticos, incluida la ejecucion de *generador.py* como subprocesso con *PYTHONPATH* vacio para garantizar que es autocontenido y que los resultados son reproducibles, requisito del punto 4 de la sec. 1.4.

8. Limitaciones conocidas y decisiones documentadas

- **El ground truth propio es la limitacion dominante del proyecto.** Los valores de $F1@3$ de la seccion 7 sirven para ordenar configuraciones entre si, no para estimar la nota: la anotacion es parcial frente a un corpus de 1826 documentos, así que un documento relevante no anotado cuenta como error y el valor real sera mayor. Ademas se juzga el documento viendo un solo fragmento — el mejor de cada documento, que no siempre es la mejor evidencia — lo que hace marcar de menos, nunca de mas.
- **No se mide $NDCG@10$,** que es la mitad del puntaje. Anotarlo exigiria relevancia graduada fragmento por fragmento. Las decisiones que afectan solo a los fragmentos se tomaron por tanto sobre argumentos estructurales y no por medicion: la supresion de duplicados exactos, por ejemplo, no puede empeorar el $NDCG$ porque el ranking ideal no contiene el mismo texto dos veces.
- **Documentos sin texto recuperable:** 8 de los 1826. Cinco son imagenes (una de ellas en formato AVIF, que Pillow no lee sin plugin adicional), una es un JSON de 0 bytes y dos son paginas HTML de error guardadas con extension .pdf. Estos ultimos se detectan por contenido y se procesan como HTML, pero su texto es una pagina de error y no aporta nada. Estos documentos quedan en el corpus sin posibilidad de ser recuperados.
- **Campo *fuentes*:** se reporta siempre el nombre de archivo estandarizado del inventario de ADL, nunca la URL de origen (que se conserva aparte, en un campo *url* adicional). La sec. 10.2.1 sugeria *fuentes* como clave de emparejamiento y la aclaracion posterior de ADL indico *doc_id*; reportar el nombre de archivo hace que el sistema funcione bajo cualquiera de las dos lecturas.
- **Fusion de chunks cortos adyacentes** (sec. 9.2.1, mencionada como posible, no obligatoria) no esta implementada: solo se implemento la division obligatoria de chunks que exceden 250 palabras.
- **Boilerplate de PDF:** la heuristica de lineas repetidas ($\geq 30\%$ de paginas) requiere documentos de 3 o mas paginas; PDFs mas cortos no reciben este filtro.